

# 面向三维重建的自适应列文伯格-马夸尔特点云配准方法



曾俊飞 杨海清 吴 浩

浙江工业大学信息工程学院 杭州 310000

(630820898@qq.com)

**摘 要** 针对三维重建时点云配准过程易受环境噪声、点云曝光、光照、物体遮挡等因素的影响,以及传统 ICP 配准算法配准精度低、耗时长等问题,提出一种基于自适应列文伯格-马夸尔特迭代式的点云配准方法。首先,对初始点云数据采用统计滤波和体素栅格滤波相结合的方式降噪预处理;然后,对滤波后的点云进行分层,剔除位于层外的外点数据,以提高后续点云配准的精度;针对传统点云特征描述方法计算量大的问题,使用平滑度参数提取点云特征,以提升点云配准的效率;最后,根据点云特征建立帧间点到线及点到面的约束关系,采用改进的列文伯格-马夸尔特(Levenberg-Marquardt)方法完成点云配准,构建较理想的三维重建模型。实验结果表明,提出的点云配准方法适用于室内及室外场景的三维重建,环境适应性强,且点云配准精度和效率都有较大提升。

**关键词:** 三维重建;点云配准;点云特征;平滑度;列文伯格-马夸尔特

**中图法分类号** TP391

## Adaptive Levenberg-Marquardt Cloud Registration Method for 3D Reconstruction

ZENG Jun-fei, YANG Hai-qing and WU Hao

College of Information Engineering, Zhejiang University of Technology, Hangzhou 310000, China

**Abstract** To address the problems that point cloud registration process in three-dimensional (3D) reconstruction is susceptible to environmental noise, point cloud exposure, illumination, object occlusion and other factors, as well as the traditional ICP registration algorithm with low accuracy and long time-consuming, this paper proposed a point cloud registration algorithm based on adaptive Levenberg-Marquardt. Firstly, the initial point cloud data is pretreated by way of statistical filtering and voxel raster filtering, and then the filtered point cloud is stratified to eliminate the outlier data, so as to improve the accuracy of subsequent point cloud registration. Furthermore, aiming at the problem that traditional point cloud feature description method is computation-intensive, smoothness parameter is adopted to conduct extracting point cloud features and improve the efficiency of point cloud registration. Finally, the point-to-line and point-to-surface constraints between frames are established on the basis of the point cloud features, and the modified Levenberg-Marquardt method is utilized to realize point cloud registration, so as to construct a satisfying 3D reconstruction model. The experimental results show that the proposed point cloud registration method is suitable for 3D reconstruction of indoor and outdoor scenes, with outstanding environmental adaptability. Meanwhile, the accuracy and efficiency of point cloud registration are greatly improved compared with the traditional methods.

**Keywords** 3D reconstruction, Point cloud registration, Point cloud feature, Smoothness, Levenberg-Marquardt

## 1 引言

随着计算机智能化的发展,社会各领域渴望运用计算机对人类所处的三维环境进行直观表达,三维重建技术由此孕育而生<sup>[1]</sup>。三维重建通过计算机对现实世界的场景进行处理和分析,建立直观的三维模型<sup>[2]</sup>。数字化的三维重建模型被广泛应用于社会各领域,例如,在游戏领域,三维建模可增强游戏的真实感;在自主导航方面,车辆或无人机上安装的激光传感器或视觉传感器,可以获取城市的三维地理信息,计算机可根据该信息绘制出三维电子地图,发送到用户智能设备的

地图软件上;在医学方面,医生利用红外线、超声波等手段获取到人体器官组织的三维模型,由三维模型直接判断器官的具体情况并诊断出病情,因此其具有很大的医学辅助作用。三维重建技术也被应用于地质勘探、工业自动化等领域<sup>[3]</sup>。

点云配准<sup>[4]</sup>是三维重建过程中的重要环节,配准的精度和效率直接影响到整个场景重建的效果。近年来,点云配准逐渐发展为两步完成。第一步是粗配准<sup>[5]</sup>,目的是减小两个点云对的初始位置间距,为精配准提供较好的初始位置。Cheng 等<sup>[6]</sup>采用标记的方法进行粗配准,该方法需要手工标记点云的特征信息,利用特征信息进行配准,工作量较大,无

到稿日期:2019-02-02 返修日期:2019-04-25 本文已加入开放科学计划(OSID),请扫描上方二维码获取补充信息。

基金项目:浙江省自然科学基金(LY13F010008);浙江省科技计划项目(2015F50009)

This work was supported by the Natural Science Foundation of Zhejiang province, China (LY13F010008) and Science and Technology Plan Project of Zhejiang province, China (2015F50009).

通信作者:杨海清(yanghq@zjut.edu.cn)

法适用于大规模场景的重建。Daniels 等<sup>[7]</sup>利用点到点的距离限制点对关系,用于剔除误匹配,但匹配的精度依赖于阈值的设置。Rusu 等<sup>[8]</sup>提出的算法的点云特征是一种点特征直方图,通过直方图判断当前点云的匹配点。基于点云线特征和面特征的粗配准工作也取得了进展,Bigand 等<sup>[9]</sup>采用模糊积分法解决场景局部立体问题,适用于含有大量直线段的场景。Dai 等<sup>[10]</sup>将局部平面不变特性作为点云特征描述子,利用点云平面参数进行粗配准工作。Sun 等<sup>[11]</sup>采用区域曲率图进行点云配准,但当重建的场景具有大量重复的局部特征时,往往会产生很多相似的点云匹配对,造成点云误匹配。

点云配准的第二步是精配准<sup>[12]</sup>,精配准是以粗配准为基础,对粗配准后的点云进一步配准。目前应用较多的精配准方法是 1992 年 Besl 等提出的最近点迭代算法(Iterative Closest Point,ICP)<sup>[13]</sup>。该算法反复迭代求解欧氏距离的最小值,当欧氏距离最小时,传感器的位姿为最优变换矩阵。该算法步骤简单易实现,但对两个点云对的初始位置有较高的依赖性,易收敛于局部最优,且占用较多的迭代时间。Mavridis 等<sup>[14]</sup>将稀疏 ICP 算法与退火搜索算法相结合,用于降低点云数据的噪声点,提高点云配准的准确率。Fan 等<sup>[15]</sup>采用高斯-凸包混合模型进行点云配准工作,用于解决点云配准的非刚性问题。Du 等<sup>[16]</sup>对 ICP 算法进行改进,构建了一种概率迭代最近点(Probability Iterative Closest Point,PICP)算法,以解决由噪声造成的误匹配问题。同时,Du 团队又提出一种尺度迭代最近点(Scaled Iterative Closest Point,SICP)的思想<sup>[17]</sup>,用于解决尺度因素造成的点云误匹配问题,但该方法仍未解决 ICP 算法易于趋向局部最优的问题。

本文提出一种基于自适应列文伯格-马夸尔特迭代式的点云配准算法。首先,使用统计滤波和体素栅格滤波相结合的方式处理初始点云数据,剔除外点数据;然后,使用平滑度参数作为特征描述子,提取特征点云,再根据特征点云的几何特征进行点云粗配准;最后,在帧间建立点到线及点到面的点云约束关系,构建自适应列文伯格-马夸尔特配准算法,对点云约束关系进行迭代优化,求解出最优匹配对,从而解决点云配准精度差、配准速度慢的问题。

2 点云预处理技术

在采集三维点云数据时,激光传感器由于受到光照、电磁场和物体粗糙表面等因素的影响,获取的点云数据掺杂很多噪声点,这些噪声点会对点云配准造成严重影响。点云处理技术在于优化点云数据,剔除噪声点及无用信息,提高后续点云配准的效率和准确性。

2.1 点云滤波

点云数据的噪声点在平面上表现为离群点,在空间上表现为孤立的、不依附于立体点云集的稀疏点云<sup>[18]</sup>。针对噪声点的存在形式,本文对点云构建统计滤波<sup>[19]</sup>和体素栅格滤波<sup>[20]</sup>相结合的混合滤波器方法。构建混合滤波器的步骤如下。

Step1 使用统计滤波器统计点云与距离它最近的  $N$  个点云的距离均值(本文取  $N=50$ ),剔除距离过大的点云,若该点云的邻近点云数少于 10,则剔除该点云,反之生成点云簇。

Step2 将点云簇的每个点云均作为体素中心点,生成  $1\text{ cm}^3$  的体素,体素内只保留一个点云数据,剔除冗余点云,重新生成点云簇。

Step3 以点云簇的中心点云作为新的体素中心点,将该体素的体积增大到  $20\text{ cm}^3$ ,若其与相邻的点云簇存在重叠区域,则剔除重叠区域里的点云。

混合滤波器在平面上保留聚集在一起的点云簇,剔除孤立的噪声点,在空间上进行降采样;剔除含有重复信息的无用点云数据,以提高后续点云配准的速度。

2.2 基于平滑度参数的特征提取

场景点云特征是表征场景中物体特点的一个重要方法<sup>[21]</sup>。为提高点云特征的提取效率,本文使用一种基于平滑度参数的方法提取点云特征,该方法分为两步:点云分层和点云特征提取。

将传感器旋转部件旋转一周所采集到的点云数据定义为一帧,再对每一帧进行分层,将属于同一激光发射通道的点云定义为同一层。定义三维点云  $P_i$  的坐标为  $\{x_i,y_i,z_i\}$ ,该点的垂直扫描角  $w$  定义为:

$$w=\arctan\left(\sqrt{\frac{z_i^2}{x_i^2+y_i^2}}\right)$$
 (1)

由垂直扫描角获取点云  $P_i$  对应的激光通道号  $L_{ID}$ ,定义激光通道号的公式为:

$$L_{ID}=\begin{cases} w>0\Rightarrow fix(w+0.5) \\ w<0\Rightarrow fix(w-0.5) \end{cases}$$
 (2)

其中,fix 为取整函数。分别计算每一帧点云数据的通道号,将属于同一激光通道号的点云定义为同一层点云,至此完成点云分层工作。

针对点云特征提取,本文使用点云邻域内点集弯曲的程度来描述点云特征,将点集弯曲的程度称为平滑度  $C$ 。为了保证提取效率,将每层点云分为 6 个区域,对每个区域先提取平滑度最大的 3 个边缘点  $P_e$ ,再提取平滑度最小的 3 个平面点  $P_h$ ,最后将大于指定阈值的点云作为普通边缘点,将小于指定阈值的点云作为普通平面点。平滑度  $C$  的定义如下:

$$C=\frac{1}{|S|}\parallel\sum_{i,j\in S,i\neq j}(P_{k,i}^L-P_{k,j}^L)\parallel$$
 (3)

其中, $S$  是给定点邻域内的点云组成的点集, $P_{k,i}^L$  表示激光传感器坐标系  $L$  下第  $k$  帧的点云  $i$  的三维坐标。平滑度  $C$  越大,给定点到其邻域内其他点的距离均值越大; $C$  越小,给定点到其邻域内其他点的距离均值则越小。

当特征点云满足以下 3 种情况时,予以剔除:

Case1 为避免特征点云过于集中,若邻域内存在若干个已标记的特征点云,则剔除该特征点云;

Case2 为保证特征点云能被其他相邻帧观测到,剔除被遮挡的特征点云;

Case3 为保证点云测距的准确性,若特征点云所在的平面与激光束相互平行,剔除该特征点云。

基于平滑度参数的特征点云的提取结果如图 1 所示,图中紫色点为平面点,蓝色点为边缘点。



图 1 房间的点云特征提取图(电子版为彩色)

Fig. 1 Point cloud feature extraction map of room

### 2.3 基于平滑度参数的粗配准

粗配准为精配准提供较好的初始位置,提高点云配准的精度。本文将获得的特征点云作为待定配准点,在对应区域内搜索与待定匹配点平滑度最相近的多个匹配点,相近程度应满足下列公式:

$$\sqrt{|C(P_{k,i}) - C(P_{k-1,j})|^2 + |C(P_{k,i}) - C(P_{k-2,m})|^2} < \epsilon \quad (4)$$

其中,  $\epsilon$  为平滑度阈值,  $C(P_{k,i})$  为第  $K$  帧第  $i$  个点云的平滑度。

当存在多个相似点对时,本文采用距离函数对每个相似点对进行相似性度量。给定点  $P_i$  与相似点  $P_j$  的相似度  $D(P_i, P_j)$  定义为:

$$M(P_i, P_j) = \left( \sum_{k=1}^m (C(P_i) - C(P_{j,k}))^2 \right)^{\frac{1}{2}} \quad (5)$$

$$D(P_i, P_j) = \frac{1}{M(P_i, P_j)} \quad (6)$$

其中,  $M(P_i, P_j)$  是平滑度距离函数,  $C(P_{j,k})$  表示相似点  $P_j$  所在区域内特征点云的平滑度,本文选取相似性最大的相似点作为  $P_i$  的匹配点。

### 3 自适应列文伯格-马夸尔特配准方法

本文采用平滑度参数作为点云特征描述子来采集平面点及边缘点,根据帧间平面点和边缘点的分布情况,构建点到线及点到面的约束关系;采用改进的列文伯格-马夸尔特方法求解最优配准,重建出更理想的三维点云地图。

#### 3.1 列文伯格-马夸尔特模型的概述

将点云配准问题转为非线性最优化问题,引入列文伯格-马夸尔特模型来求解最优配准。列文伯格-马夸尔特模型的主要思想如下。

将非线性最优问题的目标函数定义为:

$$F(x) = \sum_{i=1}^m f_i^2(x) \quad (7)$$

其中,  $f_i(x)$  为非线性函数。将  $f_i(x)$  在  $x_k$  上进行一阶泰勒展开,得到:

$$f_i(x_k + \Delta x_k) \approx f_i(x_k) + \mathbf{J}_i(x_k) \Delta x_k \quad (8)$$

其中,  $\mathbf{J}_i(x_k)$  为  $f_i(x)$  关于  $x_k$  的导数,  $\Delta x_k$  为下降量。为求解下降量,需要构造一个线性最小二乘问题:

$$\Delta x_k^* = \underset{\Delta x_k}{\operatorname{argmin}} \frac{1}{2} \| f_i(x_k) + \mathbf{J}_i(x_k) \Delta x_k \|^2 \quad (9)$$

将式(9)的平方项展开,得到:

$$\begin{aligned} & \frac{1}{2} \| f_i(x_k) + \mathbf{J}_i(x_k) \Delta x_k \|^2 \\ &= \frac{1}{2} (f_i(x_k) + \mathbf{J}_i(x_k) \Delta x_k)^T (f_i(x_k) + \mathbf{J}_i(x_k) \Delta x_k) \\ &= \frac{1}{2} (\| f_i(x_k) \|^2 + 2 f_i(x_k) \mathbf{J}_i(x_k) \Delta x_k + \Delta x_k \mathbf{J}_i(x_k)^T \mathbf{J}_i(x_k) \Delta x_k) \end{aligned} \quad (10)$$

对式(10)求导,并令其为0:

$$2 \mathbf{J}_i(x_k)^T f_i(x_k) + 2 \mathbf{J}_i(x_k)^T \mathbf{J}_i(x_k) \Delta x_k = 0 \quad (11)$$

得到如下方程:

$$\mathbf{J}_i(x_k)^T \mathbf{J}_i(x_k) \Delta x_k = -\mathbf{J}_i(x_k)^T f_i(x_k) \quad (12)$$

为了保证  $\Delta x_k$  不会下降得过快,在每次迭代时加入一个合适的阻尼因子  $\lambda$ ,更新增量方程如下:

$$(\mathbf{J}_i(x_k)^T \mathbf{J}_i(x_k) + \lambda \mathbf{I}) \Delta x_k = -\mathbf{J}_i(x_k)^T f_i(x_k) \quad (13)$$

该模型的具体计算步骤如下。

Step1 给定初始值  $x_0$ , 设置参数  $\lambda$  和迭代终止参数  $\delta$ , 计算

$$F(x_0) = \sum_{i=1}^m f_i^2(x_0).$$

Step2 对于第  $k$  次迭代, 求解出当前的雅克比矩阵  $\mathbf{J}_i(x_k)$  和误差  $f_i(x_k)$ , 将其代入式(13)求解  $\Delta x_k$ 。

Step3 若  $F(x_k + \Delta x_k) < F(x_k)$ , 且  $\|\Delta x_k\| < \delta$ , 则停止迭代, 输出结果, 反之则令  $x_{k+1} = x_k + \Delta x_k$ , 缩小  $\lambda$ , 重新求解增量方程; 若  $F(x_k + \Delta x_k) > F(x_k)$ , 则增大  $\lambda$ , 令  $x_{k+1} = x_k + \Delta x_k$ , 重新求解增量方程。

列文伯格-马夸尔特模型具有局部收敛性, 能正确处理非正定矩阵和奇异矩阵, 同时具有全局搜索特性, 对点云的初始位置的选取不严苛, 可有效提高特征点云提取的灵活性。

#### 3.2 自适应列文伯格-马夸尔特精配准方法

将当前帧最大边缘点的集合记为  $E_k$ , 最小平面点的集合记为  $H_k$ , 在上一帧点云中搜索相应的特征线和特征面。将当前帧最大边缘点集合  $E_k$  的一个点云记为  $P_{k,i}$ , 使用 kd 树<sup>[22]</sup> 搜索上一帧中离  $P_{k,i}$  最近的、同一层的点云  $P_{k-1,j}$ , 再搜索离  $P_{k,i}$  次近的、不同层但距离  $P_{k,i}$  不超过 3 层的次近点  $P_{k-1,l}$ 。  $P_{k-1,j}$  与  $P_{k-1,l}$  形成的线段就是  $P_{k,i}$  对应的特征线, 如图 2 所示。




图 2 特征线示意图

Fig. 2 Characteristic line diagram

点到特征线的距离度量公式如下:

$$\frac{|(P_{k,i}^L - P_{k-1,j}^L) \times (P_{k,i}^L - P_{k-1,l}^L)|}{|(P_{k-1,j}^L - P_{k-1,l}^L)|} = d_e \quad (14)$$

其中,  $P_{k,i}^L$  表示激光传感器坐标系  $L$  下第  $k$  帧点云  $i$  的三维坐标,  $d_e$  表示最大边缘点的距离阈值。

针对当前帧最小平面点集合  $H_k$  的一个点云  $P_{k,i}$ , 同样使用 kd 树搜索上一帧中离  $P_{k,i}$  最近的、同一层的点云  $P_{k-1,j}$ , 再搜索离  $P_{k,i}$  次近的、不同层的但距离  $P_{k,i}$  不超过 3 层的次近点  $P_{k-1,l}$  和  $P_{k-1,m}$ 。  $P_{k-1,j}$ ,  $P_{k-1,l}$  和  $P_{k-1,m}$  形成的平面就是  $P_{k,i}$  对应的特征面, 如图 3 所示。




图 3 特征面示意图

Fig. 3 Characteristic surface diagram

点到特征面的距离度量公式如下:

$$\begin{aligned} & \frac{|(P_{k,i}^L - P_{k-1,j}^L) * ((P_{k-1,j}^L - P_{k-1,l}^L) \times (P_{k-1,j}^L - P_{k-1,m}^L))|}{|(P_{k-1,j}^L - P_{k-1,l}^L) \times (P_{k-1,j}^L - P_{k-1,m}^L)|} \\ &= d_h \end{aligned} \quad (15)$$



其中,  $d_h$  是最小平面点的距离阈值。

根据点到线及点到面的距离度量, 建立匹配对的约束关系:

$$f_e(P_{k,i}^L, \mathbf{T}_k^L) = d_e, i \in E_k \quad (16)$$

$$f_h(P_{k,i}^L, \mathbf{T}_k^L) = d_h, i \in H_k \quad (17)$$

其中,  $\mathbf{T}_k^L$  表示激光坐标系  $L$  下第  $k$  帧到上一帧的位姿变换。

合并边缘点和平面点的约束关系, 得到:

$$f_k = d = \begin{pmatrix} f_e(P_{k,i}^L, \mathbf{T}_k^L) \\ f_h(P_{k,i}^L, \mathbf{T}_k^L) \end{pmatrix} \quad (18)$$

将位姿变换当作待估计状态, 结合式(11), 得到位姿求解公式:

$$\hat{\mathbf{T}}_k^L = \mathbf{T}_k^L - (\mathbf{J}_k^T \mathbf{J}_k + \lambda \mathbf{I})^{-1} \mathbf{J}_k^T f_k \quad (19)$$

由链式法则求出雅克比矩阵  $\mathbf{J}_k$ :

$$\mathbf{J}_k = \frac{\partial f_k}{\partial \mathbf{T}_k^L} = \frac{\partial f_k}{\partial P_{k,i}^L} \frac{\partial P_{k,i}^L}{\partial \mathbf{T}_k^L} \quad (20)$$

将式(20)代入式(19)可求出当前位姿变换, 然后判断其是否属于最优估计, 距离判别公式如下:

$$0 < \frac{f_k(P_{k,i}^L, \hat{\mathbf{T}}_k^L) - f_k(P_{k,i}^L, \mathbf{T}_k^L)}{|f_k(P_{k,i}^L, \mathbf{T}_k^L)|} < T_d \quad (21)$$

其中,  $T_d$  为距离阈值。若式(21)成立, 则当前位姿变换为最优估计; 反之, 增大阻尼因子  $\lambda$ , 继续迭代求解最优位姿。

利用求解的最优位姿估计定位到上一帧对应的点云  $\hat{P}_{k-1,j}$ , 当前帧点云  $P_{k,i}$  对应的匹配点  $P_{k-1,j}$  须满足下式:

$$|P_{k,i} - P_{k-1,j}| > |P_{k,i} - \hat{P}_{k-1,j}| \quad (22)$$

若式(22)成立, 则认为  $P_{k-1,j}$  是当前帧点云  $P_{k,i}$  的最优匹配点; 若不成立, 则将  $P_{k-1,j}$  置换为  $\hat{P}_{k-1,j}$ , 减小阻尼因子  $\lambda$ , 继续迭代求解最优匹配。若达到最大迭代数仍未得到最优匹配, 则剔除当前帧的特征点云, 转向下一帧的点云配准工作。

自适应列文伯格-马夸尔特算法的实现过程如图4所示。

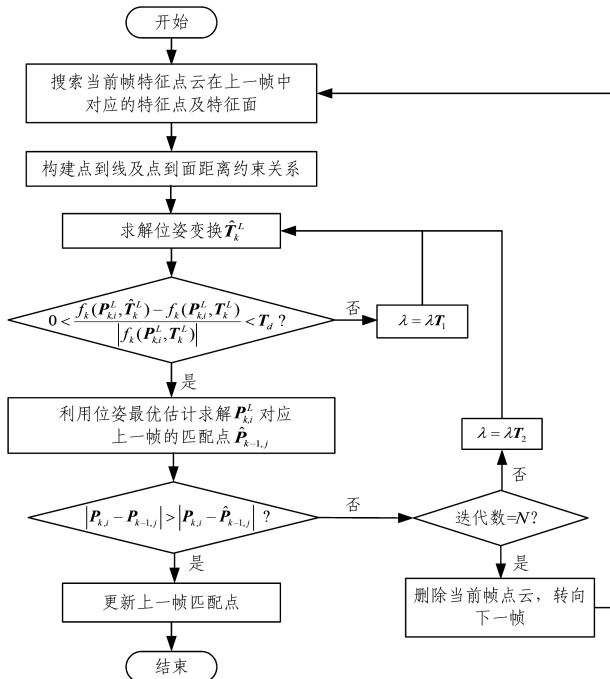


图4 自适应列文伯格-马夸尔特算法的流程图

Fig. 4 Flow chart of adaptive Levenberg-Marquart algorithm

## 4 实验结果及分析

### 4.1 实验环境

为了验证本文算法的有效性和可行性, 分别使用公共数据集和现场扫描数据进行实验。公共数据集来自斯坦福大学的 Bunny 点云样本和 Dragon 点云样本, 现场扫描数据包括室内及室外环境的点云数据。实验平台为 Intel 8 核计算机, 8GB 内存, Windows 64 操作系统, UTM-30LX 激光雷达, 旋转云台, 如图5所示。算法在 Ubuntu14.04 系统上使用 C++ 语言编程实现, 采用 OpenCV 库和 PCL 库。




图5 点云数据采集平台

Fig. 5 Point cloud data acquisition platform

### 4.2 实验结果分析

针对公共数据集, 采用传统 ICP 算法、文献[17]的 SICP 算法和本文算法进行实验, 评价指标包括点云配准耗时和点云配准误差。本文使用 C++11 标准的 Chrono 时间库计算点云的配准耗时, 在 3 种点云配准算法各自的起始端和结束端分别设置计时器, 来统计各算法进行点云配准时所消耗的时间。点云配准误差是采用均方根误差 RMS 进行度量的, 误差度量公式为:

$$RMS = (\frac{1}{S_p} \sum_{i=1}^{S_p} \| \mathbf{T}p_i - q_i \|_2^2)^{\frac{1}{2}} \quad (23)$$

其中,  $p_i$  和  $q_i$  表示待配准点云上的关键点,  $S_p$  表示点云  $p$  的配准规模。

Bunny 数据集的配准结果如图6所示。




图6 Bunny 的配准图

Fig. 6 Registration map of Bunny

图6(a)为配准前的两视角点云图, 两片点云数量分别为 33947 和 35577; 图6(b)为传统 ICP 算法的配准效果图, 可见兔子的耳朵、脖子及腹部存在较多的匹配误差; 图6(c)为

SICP 算法的配准效果图,可见兔子的腹部已匹配正确,但耳朵及脖子仍未能正确匹配;图 6(d)为本文算法的配准效果图,其基本完成兔子全身的配准工作,三维重建的完整性远高于传统的 ICP 算法。

表 1 为 3 种算法对 Bunny 样本的配准误差和配准耗时。从表中可看出,传统 ICP 算法的配准误差较大,未对点云进行有效筛选,迭代过程耗时长,配准速度缓慢;SICP 算法有效降低了配准的误差,但配准效率仍有待进一步提高;本文算法对点云数据集进行重重筛选,剔除外点数据,选择有效的匹配对,在降低配准误差的同时,大大提高了配准的效率。相比传统 ICP 算法,本文算法的配准精度提高了 66.90%,配准效率提高了 69.02%。

表 1 Bunny 的配准结果

Table 1 Registration results of Bunny		
配准方法	配准耗时/s	配准误差/mm
传统 ICP 算法	68.27	0.1435
SICP 算法	47.33	0.0694
本文算法	21.15	0.0475

为了进一步验证本文算法的有效性,使用更为复杂的 Dragon 数据集进行实验。Dragon 数据集的配准结果如图 7 所示。图 7(a)为配准前的两视角点云图,两片点云数分别为 87625 和 95423;图 7(b)为传统 ICP 算法的配准效果图,可以看到龙的头部、尾部及腹部中间区域均未能得到有效配准,配准效果整体较差;图 7(c)为 SICP 算法的配准效果图,可见龙的头部及尾部已正确匹配,但腹部仍存在较多的误匹配;图 7(d)为本文算法的配准效果图,可见 Dragon 图像整体均得到正确配准,三维重建的效果远好于 ICP 算法。




图 7 Dragon 的配准图

Fig. 7 Registration map of Dragon

表 2 为 3 种算法对 Dragon 样本的配准误差和配准耗时。从表中可以看出,随着点云数据的增大,3 种算法的配准耗时都有所增长,传统 ICP 算法的配准误差较大,且配准速度较慢;SICP 算法通过改进传统 ICP 算法,提高了配准效率,但配准误差有待降低;本文算法将配准误差降到最小,配准效率也有所改善。相比传统 ICP 算法,本文算法的配准精度提高了 72.57%,配准效率提高了 63.69%。

表 2 Dragon 的配准结果

Table 2 Registration results of Dragon		
配准方法	配准耗时/s	配准误差/mm
传统 ICP 算法	103.73	0.3431
SICP 算法	66.32	0.1538
本文算法	37.66	0.0941

针对激光扫描仪扫描的数据,采用本文算法对其进行点云配准,重建出三维点云模型。将三维重建模型与实际场景的实测数据进行比对,以进一步验证本文点云配准算法的准确性。

图 8 为室内实景及对应的三维点云效果图。为了便于实验及观测,本文只保留 6 个墙面的室内点云地图。从图 8 可以发现,本文算法能完整重建出室内场景的三维点云模型,三维模型的整体视觉效果较好,基本符合室内环境的几何特征。




图 8 室内实景与室内三维点云图

Fig. 8 Indoor scene and indoor 3D point cloud map

表 3 为点云平均距离与室内实测距离的比对结果。从表中可以看出,三维点云模型的几何尺寸与室内场景的实测距离的误差均保持在 5cm 之内,点云配准精度达到了毫米级别,证明了本文算法的有效性。

表 3 点云平均距离与室内实测距离的对比

Table 3 Comparison between average distance of point cloud and measured distance of indoor scene

(单位:m)			
	房间长	房间宽	房间高
点云平均距离	6.636	3.517	3.215
实测平均距离	6.602	3.542	3.246
误差	0.034	0.025	0.031

图 9 为室外实景及对应的三维点云效果图,图中标记了走廊墙角 A,B,C。本文通过检测三维点云图中 3 个标记点的相对距离来验证本文算法能达到的相对测量精度。




图 9 室外实景与室外三维点云图

Fig. 9 Outdoor scene and outdoor 3D point cloud map

表 4 为三维点云与室外实景的比对结果。从表中可以看出,激光扫描系统离墙角 A 的距离越远,点云配准的相对误差就越大。因为测量距离的增大会导致测量点周围的点云逐渐稀疏,会对后续特征点云的提取及点云配准造成一定的影响。但测量点若在激光扫描系统半径 10m 的扫描区域内,本文算法仍能将三维重建模型的实测误差保持在 10cm 之内,

体现了本文算法具有较强的抗噪性,在复杂的室外环境中仍具有较好的适应性。

表 4 点云平均距离与室外实测距离比对

Table 4 Comparison between average distance of point cloud and measured distance of outdoor scene

(单位:m)

系统与 A 的距离	被测物	实测距离	点云平均 距离	误差
2	A 与 B	2.448	2.423	0.025
	A 与 C	3.872	3.855	0.017
	B 与 C	3.380	3.347	0.033
5	A 与 B	2.448	2.496	0.048
	A 与 C	3.872	3.835	0.027
	B 与 C	3.380	3.421	0.041
10	A 与 B	2.448	2.523	0.075
	A 与 C	3.872	3.837	0.035
	B 与 C	3.380	3.466	0.086

**结束语** 点云配准是三维重建技术的关键环节,其精度和效率直接影响到后续重建的效果。针对传统 ICP 算法过于依赖点云初始位置及点到点匹配策略鲁棒性差的问题,本文提出一种基于自适应列文伯格-马夸尔特迭代式点云配准方法。本文通过混合滤波器剔除外点数据,以提高特征点云的提取速度;将点云平滑度参数作为点云的特征描述子,构建点到线及点到面的点云约束关系,并设计自适应列文伯格-马夸尔特迭代式方法,以提高点云配准的精度。相比传统的 ICP 算法,本文方法不仅提高了点云配准精度,同时大大改善了配准效率,其适用于室内及室外环境的三维重建,环境适应性强。本文方法也存在一定的局限性,即重建后的三维点云未包含语义信息,不利于人机交互。针对这些问题,今后的工作将结合深度学习的方法,致力于构建含有更多信息的语义化三维点云地图,以便将其应用到更加广泛的智能化领域。

参 考 文 献

[1] TAMAS V, RALPH R M, JORDAN C. Reverse engineering of geometric models — an introduction [J]. Computer-Aided Design, 1997, 29(4): 255-268.

[2] ZENG L I, ZHANG W, YANG Y. Multiple density leaf reconstruction based on limited details [J]. Computer Science, 2016, 43(8): 292-296.

[3] TONG J, ZHOU J, LIU L G, et al. Scanning 3D full human bodies using Kinects [J]. IEEE Transactions on Visualization and Computer Graphics, 2012, 18(4): 643-650.

[4] MARANI R, RENO V, NITTI M, et al. A modified iterative closest point algorithm for 3D point cloud registration [J]. Computer-Aided Civil Infrastructure Engineering, 2016, 31(7): 515-534.

[5] GUO Y L, BENNAMOUN M, SOHEL F, et al. A comprehensive performance evaluation of 3D local feature descriptors [J]. International Journal of Computer Vision, 2016, 116(1): 66-89.

[6] CHENG L, TONG L H, LI M C, et al. Semi-automatic registration of airborne and terrestrial laser scanning data using building corner matching with boundaries as reliability check [J]. Remote Sensing, 2013, 5(12): 6260-6283.

[7] DANIELS I J, OCHOTTA T, HA L K, et al. Spline-based feature curves from point-sampled geometry [J]. The Visual Computer, 2008, 24(6): 449-462.

[8] RUSU R B, BLODOW N, BEETZ M. Fast point feature histo-

grams (FPFH) for 3D registration [C] // Proceedings of IEEE International Conference on Robotics and Automation. New York: IEEE Press, 2009: 1848-1853.

[9] BIGAND A, BOUWMANS T, DUBUS J P. A new stereo matching algorithm based on linear features and the fuzzy integral [J]. Pattern Recognition Letters, 2001, 22(2): 133-146.

[10] DAI J, YANG J. A novel two-stage algorithm for accurate registration of 3-D point clouds [C] // Proceedings of the International Conference on Multimedia Technology. New York: IEEE Press, 2011: 6187-6191.

[11] SUN J, ZHANG J, ZHANG G. An automatic 3D point cloud registration method based on regional curvature maps [J]. Image and Vision Computing, 2016, 56: 49-58.

[12] CHOI S, ZHOU Q Y, KOLTUN V. Robust reconstruction of indoor scenes [C] // Proceedings of IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2015: 5556-5565.

[13] BESL P J, MCKAY N D. A method for registration of 3-D shapes [J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 1992, 14(2): 239-256.

[14] MAVRIDIS P, ANDREADIS A, PAPAIOANNOU G. Efficient Sparse ICP [J]. Computer Aided Geometric Design, 2015, 35(C): 16-26.

[15] FAN J F, YANG J, AI D, et al. Convex hull indexed Gaussian mixture model (CH-GMM) for 3D point set registration [J]. Pattern Recognition, 2016, 59: 126-141.

[16] DU S, LIU J, ZHANG C J. Probability iterative closest point algorithm for m-D point set registration with noise [J]. Neurocomputing, 2015, 157: 187-198.

[17] XU S Y, ZHU J H, LI Y C, et al. Effective scaling registration approach by imposing emphasis on scale factor [J]. Electronics Letters, 2018, 54(7): 422-424.

[18] SUN Z L. Research on filtering method of 3D laser scanning point cloud data [D]. Hunan: Central South University, 2011.

[19] GENG N, MA F F, YANG H J, et al. Neighboring Constraint-based pairwise point cloud registration algorithm [J]. Multimedia Tools and Applications, 2016, 75(24): 16763-16780.

[20] ZHOU R R, ZHANG L Y, SU X, et al. Algorithmic research on surface reconstruction from dense scattered points [J]. Journal of Software, 2001, 12(2): 249-255.

[21] DEBAYLE J, PRESLES B. Rigid image registration by General Adaptive Neighborhood matching [J]. Pattern Recognition, 2016, 55: 45-57.

[22] BENTLEY J L. Multidimensional binary search trees used for associative searching [J]. Communications of the ACM, 1975, 18(9): 509-517.



**ZENG Jun-fei**, born in 1993, postgraduate. His main research interests include visual SLAM and three-dimensional reconstruction.



**YANG Hai-qing**, born in 1971, associate professor, postgraduate supervisor. His main research interests include computer vision and so on.